

TRANSITION ENERGETIQUE DE NOVARIA

ETL et aide à la décision dans Power BI

TAKARROUHT Hamza

3IL EADL2



Table des matières

Données et démarche générale 3
Étape 1 - Connexion aux sources 4
Étape 2 - Contrôle de la qualité 4
Météo (Controle_Meteo) 6
Tarifs, audits et consommations 6
Étape 4 - Rejets et dédoublonnage 7
Étape 5 - Combinaison des sources 8
Étape 6 - Modélisation en étoile 9
Étape 7 - Restitution 10
Bilan 10

Données et démarche générale

Source	Format et connecteur	Contenu
Consommations	SQL Server, vue VW_ConsommationsEnergetiques	Relevés par bâtiment, énergie et date, de janvier 2024 à juin 2026
Météo par quartier	Classeur Excel	Températures, pluviométrie, DJU de chauffage et ensoleillement par quartier et par mois
Tarifs	Fichier CSV	Prix du kWh et abonnement par énergie et date d'effet
Audits énergétiques	Fichier JSON	Classe énergétique, priorité, recommandation et coût estimé des travaux

Les requêtes ont été organisées en groupes numérotés qui matérialisent le trajet de la donnée, selon une logique de couches (brut, nettoyé, modèle). Une requête ne dépend que des groupes placés avant elle.

Groupe	Requêtes	Rôle
00_brute	Copies des sources	Conserver la donnée telle qu'elle arrive
01_Referentiels	Ref_Batiment, Ref_Quartier, Ref_TypeEnergie	Listes officielles de codes, issues de la base SQL
02_staging	Stg_Consommations, Stg_Meteo, Stg_Tarifs, Stg_Audits	Connexion et typage minimal, sans correction
03_Controles	Ctl_Vides_, Ctl_Doublons_, Controle_, Rejets_	Détecter les anomalies et tracer les lignes exclues
04_Intermediaires	Int_Consommations, Int_Meteo, Int_Tarifs, Int_Audits	Données valides, une ligne par grain
05_Modele	FactEnergie, FactAudit, DimBatiment, DimQuartier, DimEnergie, DimDate	Tables chargées dans le modèle

Cette organisation en groupes numérotés reprend le principe d'une architecture en couches, où la donnée passe par des états successifs : brute, contrôlée, nettoyée, puis modélisée. Le numéro de chaque groupe indique sa place dans la chaîne, et une requête ne s'appuie que sur les groupes qui la précèdent, ce qui rend le flux lisible de haut en bas et évite les dépendances croisées. Chaque groupe n'a qu'une seule responsabilité : le staging se limite à la connexion, les contrôles détectent les anomalies sans rien supprimer, et les intermédiaires ne contiennent que des lignes valides. Cette séparation présente trois avantages. D'abord la traçabilité : la donnée d'origine reste disponible, on peut donc la comparer à la donnée nettoyée et justifier chaque écart, et toute ligne écartée est conservée avec son motif. Ensuite la maintenance : lorsqu'une anomalie apparaît, on sait dans quel groupe chercher, et une correction se fait à un seul endroit. Enfin la fiabilité du modèle : le rapport ne voit que les tables du dernier groupe, déjà contrôlées et dédoublonnées, sans requête technique visible par l'utilisateur.

Étape 1 - Connexion aux sources

Les quatre connexions sont créées depuis Accueil, Obtenir les données. Le mode Import est retenu : les volumes sont faibles et trois sources sur quatre sont des fichiers.

- SQL Server : connexion au serveur local et à la base Novaria, puis sélection de la vue VW_ConsommationsEnergetiques, qui réunit déjà relevés, bâtiments, quartiers et énergies. Les tables Batiment, Quartier et TypeEnergie sont importées séparément pour servir de référentiels.
- Excel : sélection du tableau MeteoQuartierBrut. Les colonnes de mesure et la date sont laissées en type « quelconque », car elles mélangent nombres, textes et dates : un typage immédiat aurait produit des erreurs.
- CSV : séparateur point-virgule, encodage UTF-8, promotion de la première ligne en en-têtes. Le prix est gardé en texte, car il contient des symboles et des points décimaux.
- JSON : la liste est convertie en table, puis les enregistrements sont développés deux fois (Table.ExpandRecordColumn), le second niveau correspondant à l'objet imbriqué « audit ».

À ce stade, aucune valeur n'est corrigée : le staging reste une image fidèle de la source, ce qui permet de comparer à tout moment la donnée d'origine et la donnée nettoyée.

Étape 2 - Contrôle de la qualité

Avant toute correction, les données sont observées. Les outils de profilage de Power Query (onglet Affichage : qualité, distribution et profil des colonnes) donnent une première vue des valeurs vides, des erreurs et du nombre de valeurs distinctes. Deux familles de requêtes de contrôle complètent cette observation, sans rien supprimer.

- **Ctl_Vides_ :** une colonne personnalisée RaisonControle signale les clés absentes (code, date, quantité), puis un filtre ne garde que les lignes signalées.
- **Ctl_Doublons_ :** un regroupement (Regrouper par) sur la clé métier compte les occurrences, puis un filtre garde les clés présentes plus d'une fois. Les clés utilisées sont bâtiment + énergie + date pour les consommations, quartier + date pour la météo, énergie + mois pour les tarifs, bâtiment + date pour les audits.

Pour la météo, la requête Ctrl_Doublon_MeteoQuartier affine ce contrôle : elle calcule le nombre d'occurrences (NbOccurence) et le nombre de variantes de mesures (NbVariantes), afin de distinguer une ligne simplement répétée d'un vrai conflit entre deux relevés.

Ces contrôles ont mis en évidence les anomalies suivantes : codes quartier mal saisis, unités écrites dans les cellules, dates dans une dizaine de formats, mesures négatives et doublons pour la météo ; prix négatif, doublon

et espace dans un code pour les tarifs ; bâtiment inconnu, unité dans une valeur et coût absent pour les audits. La source SQL ne présente aucune anomalie.

Étape 3 - Nettoyage et normalisation

Le nettoyage est réalisé dans les requêtes Controle_, à l'aide des commandes de l'onglet Transformer. Il porte sur quatre types de défauts. Les codes (quartier, énergie, bâtiment) sont d'abord normalisés par trois commandes appliquées dans cet ordre : Nettoyer, qui retire les caractères non imprimables, Supprimer les espaces, puis Majuscules ; pour la météo, quatre remplacements de valeurs ramènent ensuite les variantes de saisie aux codes officiels (« - » supprimé, S0U remplacé par SOU, NORD par NOR, OUEST par OUE). Sans cette normalisation, un même quartier écrit de deux façons serait traité comme deux quartiers différents et ne trouverait pas de correspondance dans le référentiel. Les valeurs numériques saisies avec leur unité sont ensuite corrigées : la colonne est passée en type Texte, les unités (« °C », « mm », « DJU », « h », « € », « kWh/m² ») sont remplacées par une chaîne vide avec Remplacer les valeurs, le point décimal est remplacé par une virgule, puis la colonne est convertie en Nombre décimal. Ce détour par le texte est nécessaire, car une cellule contenant une unité ne peut pas être calculée, et les paramètres régionaux français ne reconnaissent pas « 4.2 » comme un nombre. Les dates de la météo, écrites dans une dizaine de formats, sont harmonisées par quelques remplacements (« 1er » en « 1 », « sept. » en « septembre », « mars-24 » en « mars 2024 »), puis converties par une colonne personnalisée qui essaie d'abord de lire un numéro de série Excel, ensuite une date en français (paramètre de culture « fr-FR ») ; une valeur qui échoue aux deux essais reste vide et sera rejetée. Enfin, des colonnes dérivées sont ajoutées pour préparer la suite: le mois, ramené au premier jour par Date.StartOfMonth, sert de clé commune entre les sources, et les colonnes StatutChiffrage et MotifQualite signalent une valeur manquante au lieu de la masquer. Toutes ces corrections sont des étapes enregistrées dans le volet « Étapes appliquées»: elles restent lisibles, modifiables, et se rejouent à chaque actualisation, sans qu'aucun fichier source ne soit modifié à la main.

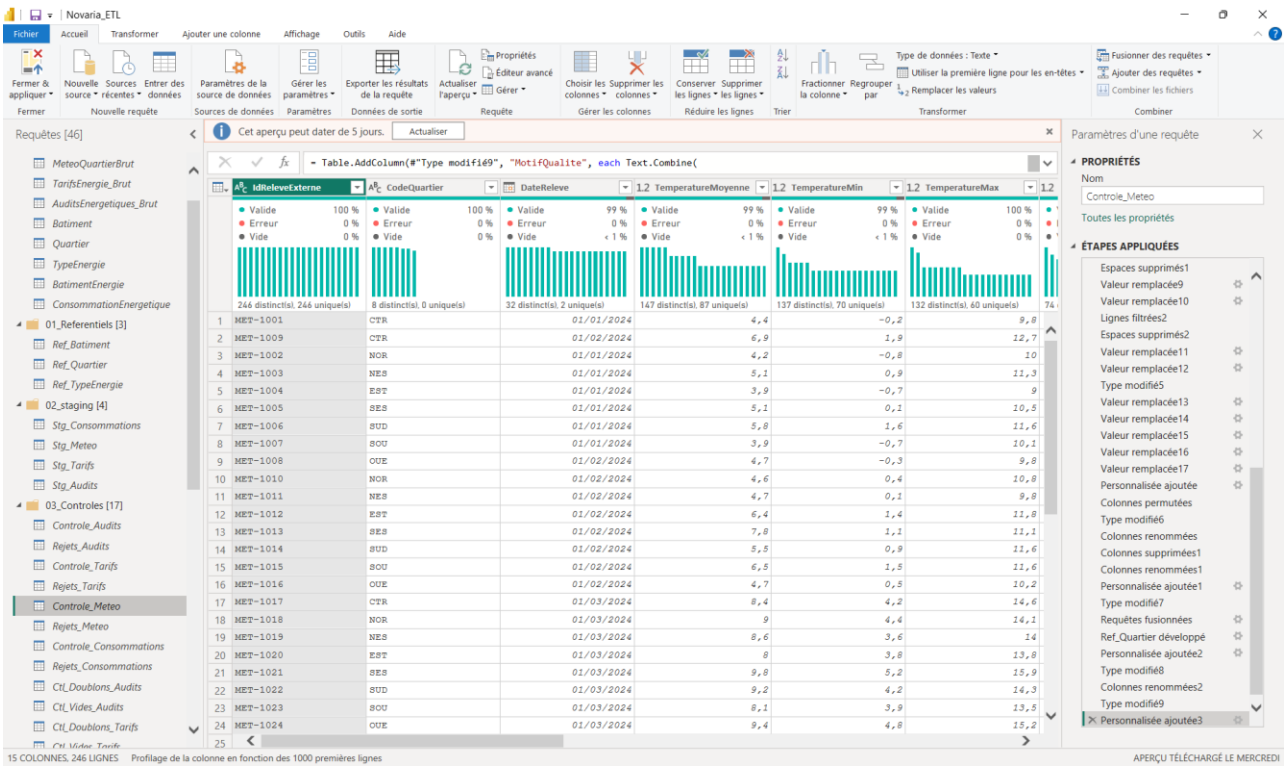


Figure 1 - Éditeur Power Query : groupes de requêtes à gauche, étapes appliquées de Controle_Meteo à droite

Météo (Controle_Meteo)

Problème constaté	Transformation appliquée	Justification
Codes quartier irréguliers	Nettoyer, Supprimer les espaces, Majuscules ; remplacement de « - » par rien, de S0U par SOU, de NORD par NOR et de OUEST par OUE	Ramener les codes aux huit codes officiels, sinon la jointure avec le référentiel échoue
Unités dans les cellules	Passage en texte, remplacement de « °C », « mm », « DJU » et « h » par rien, suppression des espaces	Une cellule contenant une unité est un texte et ne peut pas être calculée
Séparateur décimal	Remplacement du point par la virgule, puis type Nombre décimal	Avec les paramètres régionaux français, « 4.2 » n'est pas reconnu comme un nombre
Dates hétérogènes	Remplacement de « 1er », « sept. », « mars-24 », « août 25 » ; colonne personnalisée de conversion (voir ci-dessous)	Obtenir une vraie date, quel que soit le format d'origine
Grain mensuel	Colonne Mois = Date.StartOfMonth([DateReleve])	Disposer d'une clé commune avec les consommations
Valeurs manquantes	Colonne MotifQualite (« DJU manquant », « Ensoleillement manquant »)	Signaler une mesure absente sans rejeter toute la ligne

La conversion des dates est la seule transformation qui a demandé une formule. Elle essaie d'abord de lire un numéro de série Excel, puis une date écrite en français ; si les deux échouent, la valeur reste vide et la ligne sera rejetée à l'étape suivante.

```
if [DateReleve] = null then null
else try Date.From(Number.FromText([DateReleve]))
otherwise try Date.FromText([DateReleve], "fr-FR")
otherwise null
```

Tarifs, audits et consommations

Requête	Transformations appliquées	Justification
Controle_Tarifs	Suppression des lignes strictement identiques ; code énergie nettoyé et mis en majuscules ; retrait du symbole € et remplacement du point par la virgule, puis type Nombre ; MoisTarif renommée DateEffet et nouvelle colonne MoisTarif au premier jour du mois ; abonnement vide du solaire remplacé par 0	Rendre le prix calculable et le code joignable. La date d'effet servira à retrouver le tarif en vigueur. Le solaire n'a pas d'abonnement : zéro est ici la valeur réelle, pas une valeur inventée
Controle_Audits	Colonnes renommées ; code bâtiment et priorité nettoyés et mis en majuscules ; retrait de « kWh/m² » puis type Nombre ; colonne StatutChiffrage (« À chiffrer » si le coût est vide, sinon « Chiffré »)	Harmoniser les noms et les codes. Un coût absent reste vide : le remplacer par zéro signifierait que les travaux sont gratuits

Int_Consommations	Codes nettoyés et mis en majuscules ; colonne Mois ; colonnes ConsoKWhParM2 et EmissionCO2KgParM2, laissées vides si la surface est nulle ou absente	Obtenir un grain mensuel et des ratios comparables entre bâtiments, sans erreur de division par zéro

Étape 4 - Rejets et dédoublonnage

Dans chaque requête Controle_, une fusion externe gauche avec le référentiel correspondant (Accueil, Fusionner des requêtes) ramène l'identifiant officiel : un identifiant vide révèle un code inconnu. Une colonne conditionnelle RaisonRejet écrit ensuite le motif d'exclusion de la ligne, ou reste vide si la ligne est valide.

- **Rejets_ :** référence à Controle_, filtrée sur RaisonRejet non vide. Les lignes écartées sont conservées avec leur motif.
- **Int_ :** référence à Controle_, filtrée sur RaisonRejet vide. Elle ne contient que des lignes valides.

Cette séparation évite toute suppression silencieuse et permet de vérifier l'égalité : lignes au départ = lignes valides + rejets + doublons retirés.

Le dédoublonnage est fait dans les requêtes Int_. Pour les consommations et la météo, les lignes sont triées par date de chargement décroissante, puis Supprimer les doublons est appliqué sur la clé métier (bâtiment + énergie + date, quartier + mois), ce qui conserve la ligne la plus récente. Le tri est figé par Table.Buffer avant la suppression : sans cette étape, Power Query ne garantit pas que l'ordre du tri soit respecté au moment de retirer les doublons. Pour les tarifs, les lignes identiques ayant déjà été retirées, la suppression porte sur énergie + date d'effet.

Source	Motifs de rejet rencontrés	Départ	Valides	Rejets	Doublons
Consommations	Aucun	26 448	26 448	0	0
Météo	4 mesures négatives, 2 températures incohérentes, 1 date non interprétable (« 2026 T2 »)	246	228	7	11
Tarifs	1 prix négatif (réseau de chaleur au 01/07/2026)	19	17	1	1
Audits	1 bâtiment inconnu (BAT-INCONNU)	13	12	1	0

Étape 5 - Combinaison des sources

La table de faits FactEnergie est construite à partir d'Int_Consommations, enrichie par deux fusions.

- **Météo :** fusion externe gauche sur quartier + mois, puis développement de la température moyenne et des DJU. Une colonne logique MeteoTrouvee indique si une correspondance existe. La jointure gauche garantit qu'aucun relevé n'est perdu.
- **Tarifs :** fusion externe gauche sur l'énergie seule, qui rattache à chaque relevé tous les tarifs de cette énergie. Une colonne personnalisée choisit ensuite le tarif en vigueur, c'est-à-dire le plus récent dont la date d'effet précède ou égale le mois du relevé.

```
let Candidats = Table.SelectRows([Int_Tarifs], (t) => t[DateEffet] <= [Mois])
in  if Table.IsEmpty(Candidats) then null
    else Table.Max(Candidats, "DateEffet")[PrixKWhEuro]
```

Une jointure exacte sur énergie + mois n'aurait pas convenu : les tarifs ne changent que deux fois par an, la plupart des mois seraient restés sans prix. Le coût est ensuite recalculé (quantité × prix applicable, arrondi à deux décimales) et l'écart avec le coût fourni par la source est conservé dans la colonne EcartCout.

Contrôles après combinaison. FactEnergie compte toujours 26 448 lignes : les fusions n'ont dupliqué aucun fait. 1 272 relevés (4,8 %) n'ont pas de météo et 3 655 (13,8 %) n'ont pas de tarif, le solaire n'ayant aucun tarif avant 2026. Le coût recalculé est inférieur de 307 230 € au coût source, qui n'applique pas les changements de tarif.

Étape 6 - Modélisation en étoile

Les dimensions DimBatiment, DimQuartier et DimEnergie sont obtenues par référence à Int_Consommations : on ne garde que les colonnes descriptives, puis on supprime les doublons sur l'identifiant, ce qui garantit une clé unique. DimDate est générée dans Power Query (List.Dates, 1 096 jours à partir du 1er janvier 2024), enrichie des colonnes Année, Trimestre, N° mois, Mois et Année-Mois, puis marquée comme table de dates. FactAudit reprend Int_Audits.



Figure 2- Vue de modèle : deux tables de faits et quatre dimensions

Les cinq relations sont de type plusieurs à un et à sens unique, de la dimension vers le fait : FactEnergie vers DimBatiment, DimEnergie et DimDate ; DimBatiment vers DimQuartier ; FactAudit vers DimBatiment. Le schéma en étoile a été préféré à une table unique, car il évite de répéter les descriptions et rend les filtres simples et non ambigus.

Les calculs sont ensuite écrits en DAX. La différence entre colonne calculée et mesure a été mise en pratique : la colonne « Niveau consommation » (Élevée au-dessus de 10 000 kWh, sinon Normale) est évaluée ligne par ligne au chargement et sert de catégorie, tandis que les mesures sont recalculées selon les filtres du rapport.

```
Consommation totale = SUM(FactEnergie[QuantiteKWh])
Consommation N-1 = CALCULATE([Consommation totale], DATEADD(DimDate[Date], -1, YEAR))
kWh/m² = DIVIDE([Consommation totale], [Surface analysée])
```

Étape 7 - Restitution

Le rapport comprend quatre pages principales, chacune répondant à une question : synthèse des consommations, lien entre climat et consommation, coûts et tarifs, priorités de rénovation. Une page de détail par bâtiment est accessible par extraction, et les segments Année et Quartier sont synchronisés entre les pages. Le choix des visuels suit la nature des données : courbe pour une évolution dans le temps, barres horizontales pour un classement, nuage de points pour la relation entre deux mesures, moyenne et non somme pour un prix.

En complément, un diagramme radar (visuel Radar Chart de Microsoft) compare les profils mensuels de 2025 et de 2026 de janvier à juin, à l'aide de deux mesures qui fixent l'année par CALCULATE. La colonne Mois est triée par N° mois pour conserver l'ordre du calendrier.

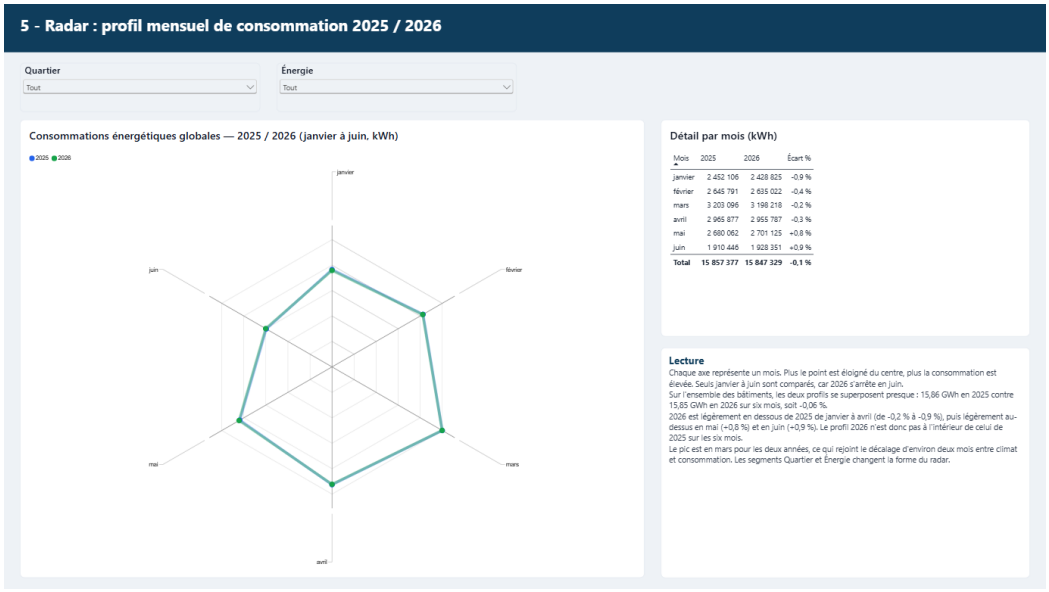


Figure 3 - Page du rapport : radar 2025 / 2026

Bilan

Résultat obtenu. La chaîne complète fonctionne de la source au rapport : quatre sources connectées, 46 requêtes organisées en couches, six tables chargées dans un modèle en étoile, et une actualisation qui rejoue l'ensemble des corrections sans intervention manuelle.

Points délicats. Trois étapes ont demandé le plus de réflexion : la conversion des dates de la météo, où coexistent des numéros de série Excel et des dates écrites en toutes lettres ; le rattachement du tarif par date d'effet, impossible avec une jointure classique ; et le dédoublonnage, dont le résultat dépend de la stabilité du tri.

Limites. Les données de 2026 s'arrêtent en juin. Une partie des relevés reste sans météo ou sans tarif, ce que les indicateurs MeteoTrouvee et TarifTrouve rendent visible. Le profilage des colonnes porte par défaut sur les mille premières lignes.

Enseignements. Ces travaux montrent qu'un ETL fiable repose moins sur la complexité des formules que sur la méthode : ne jamais corriger la source, séparer le contrôle du nettoyage, tracer chaque ligne écartée et vérifier les volumes après chaque fusion.